

Laporan Praktikum Kontrol Cerdas

Nama : Alam Syah Putra Aulia
NIM : 224308003
Kelas : TKA 6A
Akun Github (Tautan) : <https://github.com/Alamsyah003>
Student Lab Assistant : Yulia Brillianty

1. Judul Percobaan

Reinforcement Learning for Autonomous Control

2. Tujuan Percobaan

Tujuan dari praktikum ini adalah sebagai berikut

1. Mahasiswa dapat memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
2. Mahasiswa dapat mengimplementasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
3. Mahasiswa dapat menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
4. Mahasiswa dapat melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
5. Mahasiswa dapat menggunakan GitHub untuk version control dan dokumentasi praktikum.

3. Landasan Teori

Reinforcement Learning (RL) merupakan salah satu cabang kecerdasan buatan yang sedang berkembang dan banyak diteliti. Perbedaan dari RL dengan cabang lain pada studi kecerdasan buatan adalah algoritma pada RL tidak belajar dari korelasi antara masukan dan keluaran yang seharusnya. Namun algoritma ini belajar dari feedback atau timbal balik yang dia dapat saat dia memberikan suatu keluaran atau aksi dari masukan yang ia terima. Dengan metode pembelajaran ini, algoritma RL bisa menyelesaikan berbagai masalah yang penyelesaiannya tidak bisa diberikan langsung oleh manusia sehingga algoritma harus mencari sendiri jawaban dari permasalahannya, seperti control pada robot, mengemudikan mobil, bermain gim dan

sebagainya (Irvansyah, 2020). Deep Q-Network (DQN) adalah algoritma dalam reinforcement learning yang menggabungkan Q learning dengan jaringan saraf dalam untuk menyelesaikan masalah kompleks, sehingga memungkinkan agen untuk belajar dari pengalaman dan membuat keputusan dalam lingkungan yang rumit (Baradja & Tjendrowasono, 2024). OpenAI Gym merupakan pustaka pengembangan algoritma RL yang bersifat open source yang yang dibuat oleh tim OpenAI. Pustaka ini ditulis dalam bahasa pemrograman python yang banyak digunakan oleh peneliti machine learning dan data sciences untuk mengembangkan dan mengimplementasikan berbagai algoritma (Irvansyah, 2020).

4. Analisis dan Diskusi

Analisis

- **Bagaimana performa agen dalam mengontrol environment CartPole?**

Di lingkungan CartPole, agen harus menentukan kapan mendorong gerobak ke kiri atau kanan agar tiang tetap seimbang, meskipun pada awalnya tidak tahu caranya. Untuk belajar, agen mencoba berbagai tindakan secara acak dan melihat hasilnya berdasarkan reward yang diperoleh.

- **Bagaimana perubahan parameter (misal: gamma, epsilon, learning rate) mempengaruhi kinerja agen?**

Jika nilai gamma tinggi, agen akan lebih fokus pada reward jangka panjang, yang membantu meningkatkan stabilitas pembelajaran. Sebaliknya, jika gamma rendah, agen lebih mengutamakan reward instan, yang dapat mempercepat proses belajar. Untuk epsilon, nilai tinggi mendorong agen melakukan lebih banyak eksplorasi dengan mencoba aksi secara acak, sehingga cocok untuk tahap awal pelatihan. Sebaliknya, nilai epsilon yang rendah membuat agen lebih sering memilih aksi terbaik (eksploitasi), sehingga lebih efektif di tahap akhir pelatihan. Pada learning rate, nilai yang tinggi memungkinkan agen belajar lebih cepat, tetapi berisiko tidak stabil dan rentan terhadap overfitting. Sebaliknya, nilai learning rate yang rendah membuat pembelajaran lebih lambat, namun lebih stabil dan dapat meningkatkan performa jangka panjang.

- **Apa tantangan yang muncul selama pelatihan agen RL?**

Agen terkadang mengalami perubahan reward yang tidak menentu, sehingga membuat pembelajaran menjadi kurang stabil. Menyeimbangkan antara mencoba aksi baru (eksplorasi) dan menggunakan aksi yang sudah terbukti efektif (eksploitasi) menjadi tantangan tersendiri. Selain

itu, proses pelatihan, terutama dengan algoritma seperti DQN, memerlukan waktu yang cukup lama.

Diskusi

- **Perbedaan Utama antara Reinforcement Learning dan Supervised Learning**

RL menggunakan pendekatan trial and error, di mana agen belajar dengan berinteraksi langsung dengan lingkungan dan menerima reward atau penalti sebagai umpan balik. Tujuannya adalah menemukan strategi terbaik untuk memaksimalkan reward dalam jangka panjang. Sementara itu, Supervised Learning belajar dari data berlabel, di mana model diberikan contoh input dan output yang benar untuk menemukan pola dan membuat prediksi akurat. RL lebih sering digunakan dalam game AI, robotika, dan pengambilan keputusan otonom, sedangkan Supervised Learning banyak diterapkan dalam klasifikasi gambar, pemrosesan bahasa alami, dan prediksi berbasis data.

- **Bagaimana strategi eksplorasi (exploration) dan eksploitasi (exploitation) dapat dioptimalkan pada agen RL?**

Eksplorasi berarti agen mencoba aksi-aksi baru untuk menemukan strategi yang lebih baik, sementara eksploitasi berarti agen memilih aksi terbaik berdasarkan pengalaman sebelumnya.

- **Potensi aplikasi lain dari RL dalam sistem kendali nyata apa saja yang dapat diimplementasikan**

Robotika, RL digunakan untuk mengendalikan pergerakan robot, baik dalam hal navigasi maupun manipulasi objek, sehingga robot dapat bergerak lebih cerdas dan efisien di berbagai lingkungan.

Kendaraan otonom, RL membantu dalam mengoptimalkan pengambilan keputusan, seperti dalam sistem kemudi, percepatan, dan pengereman, sehingga mobil self-driving dapat beroperasi dengan lebih aman dan responsif terhadap kondisi jalan yang dinamis.



5. Assignment

Pada tugas ini, program dilatih dan diuji dengan environment MountainCar-v0. Untuk meningkatkan stabilitas pembelajaran, ditambahkan target network yang diperbarui setiap 10 episode. Prosesnya tetap sama, yaitu menjalankan pelatihan terlebih dahulu, lalu menguji agen untuk mengevaluasi performanya. Hasil pelatihan di MountainCar menunjukkan karakteristik yang berbeda dari CartPole. Pada CartPole, skor tinggi menandakan agen berhasil menjaga keseimbangan tiang lebih lama. Sebaliknya, di MountainCar, skor rendah justru lebih baik karena agen mencapai puncak bukit lebih cepat. Hal ini terjadi karena sistem reward di MountainCar

memberi nilai negatif hingga agen berhasil mencapai tujuan, sehingga semakin cepat sampai, semakin kecil skornya. Selain perbedaan dalam cara menilai skor, tujuan utama kedua environment juga berbeda. CartPole bertujuan menjaga keseimbangan tiang dengan menggerakkan troli ke kiri atau kanan, sementara MountainCar mengharuskan agen mengayun maju-mundur untuk mengumpulkan momentum hingga mencapai puncak bukit.

6. Data dan Output Hasil Pengamatan

Sajikan data dan hasil yang diperoleh selama percobaan. Gunakan tabel untuk menyajikan data jika diperlukan.

No	Variabel	Hasil Pengamatan
1	Hasil Environment CartPole	
2	Data hasil uji environment	<pre>Episode: 993/1000, Score: 188, Epsilon: 0.01 Episode: 994/1000, Score: 232, Epsilon: 0.01 Episode: 995/1000, Score: 352, Epsilon: 0.01 Episode: 996/1000, Score: 272, Epsilon: 0.01 Episode: 997/1000, Score: 210, Epsilon: 0.01 Episode: 998/1000, Score: 219, Epsilon: 0.01 Episode: 999/1000, Score: 243, Epsilon: 0.01 Episode: 1000/1000, Score: 366, Epsilon: 0.01</pre>
3	Hasil Environment MountainCar-v0	

7. Kesimpulan

Hasil eksperimen menunjukkan bahwa agen belum dapat mengontrol environment MountainCar dengan baik. Skor pelatihan tidak mengalami penurunan yang signifikan, sehingga skor pengujian tetap tinggi. Ini menandakan bahwa agen masih kesulitan menemukan strategi yang efektif untuk mencapai tujuan secara lebih efisien.

8. Saran

Untuk percobaan selanjutnya dapat dilakukan penyesuaian parameter guna meningkatkan performa dan pengimplementasian pada permasalahan yang ada di dunia nyata

9. Daftar Pustaka

- Baradja, A., & Tjendrowasono, T. I. (2024). Pengaplikasian Deep Reinforcement Q-Learning Untuk Prediksi Perdagangan Valas Otomatis. *Jurnal Rekayasa Sistem Informasi dan Teknologi*, 1(3), 190–198. <https://doi.org/10.59407/jrsit.v1i3.519>
- Irvansyah, M. A. (2020). *Implementasi Metode Reinforcement Learning Pada Simulasi Pergerakan Robot Multi-Sendi*.